

PONTIFICIA UNIVERSIDAD JAVERIANA

Procesamiento de Datos a Gran Escala

Plan de acción basado en datos para la reducción de arrestos y siniestros viales en la ciudad de Nueva York

Entrega 1. Entendimiento del negocio y entendimiento de los datos

Equipo consultor

Aldana · Ávila · Pardo

Documento elaborado para el equipo de gobierno del estado de Nueva York

2 de octubre de 2026

1. Entendimiento del negocio

1.1 Contexto general de la ciudad de Nueva York

La ciudad de Nueva York constituye el mayor centro urbano de los Estados Unidos y uno de los principales nodos económicos del mundo. Con una población estimada de 8.585.000 habitantes a julio de 2025, distribuida en cinco distritos administrativos de características muy dispares, concentra en apenas 778 kilómetros cuadrados una densidad poblacional, una diversidad demográfica y una intensidad de actividad económica sin equivalente en el país.

Esta escala explica por qué los indicadores de seguridad ciudadana y de seguridad vial resultan particularmente sensibles para el equipo de gobierno. Un desplazamiento de pocos puntos porcentuales en la cantidad de arrestos o de siniestros se traduce en miles de eventos adicionales al año, con su correspondiente costo humano, judicial y fiscal. Al mismo tiempo, la heterogeneidad entre distritos implica que una política uniforme para toda la ciudad resulta necesariamente ineficiente: lo que el Bronx requiere no coincide con lo que requiere Staten Island.

El territorio presenta además una marcada asimetría socioeconómica. El presente estudio estima, sobre los microdatos del censo correspondientes a 2023, que el 18,00% de la población vive bajo el umbral de pobreza, con una variación que va del 12,70% en Staten Island al 27,67% en el Bronx. Esa brecha de casi quince puntos porcentuales entre distritos de una misma ciudad constituye el telón de fondo de cualquier diagnóstico sobre seguridad.

1.2 Indicadores macroeconómicos de interés

Se seleccionaron los siguientes indicadores por su relación directa con la capacidad fiscal del gobierno para financiar intervenciones y con las condiciones materiales de la población sobre la que se pretende incidir.

Indicador	Valor	Periodo	Fuente
Población de la ciudad	8.585.000 hab.	Julio 2025	NYC Dept. of City Planning
Tasa de desempleo	5,1%	Septiembre 2025	NYC Comptroller
Razón empleo-población	58,7% (máximo histórico)	Ene–Sep 2025	NYC Comptroller
Producto metropolitano bruto	> 2,6 billones USD	2024	NYCEDC
Tasa de pobreza	18,00%	2023	Cálculo propio sobre ACS PUMS
Presupuesto DOT — operación vial	463 millones USD	FY 2026	NYC DOT
Plan de capital DOT	33.500 millones USD	FY 2025–2035	NYC DOT

La lectura conjunta de estos indicadores revela una tensión relevante para el encargo: la ciudad atraviesa un momento de empleo históricamente alto y dispone de una capacidad de inversión considerable en infraestructura vial, pero ese desempeño agregado convive con una incidencia de la pobreza que supera el 27% en el distrito más afectado. La prosperidad no se distribuye de manera homogénea sobre el territorio, y es precisamente esa distribución desigual la que este proyecto se propone relacionar con los indicadores de seguridad.

1.3 Situación de los indicadores objeto del encargo

Conviene precisar el punto de partida, puesto que ninguno de los dos indicadores se encuentra en una situación de deterioro descontrolado.

En materia de seguridad vial, la ciudad cerró 2025 con 205 fallecidos en siniestros de tránsito, la cifra más baja jamás registrada desde que existen estadísticas, en 1910, lo que representa una reducción del 19% frente a los 253 fallecidos del año anterior. La iniciativa Vision Zero, vigente desde 2014, ha sido el instrumento principal de esa trayectoria. El análisis efectuado sobre los datos confirma la tendencia: los siniestros registrados pasaron de un máximo de 231.564 en 2018 a 85.546 en 2025.

En materia de arrestos, la serie histórica muestra un descenso sostenido desde el máximo de 422.322 arrestos en 2010 hasta el mínimo de 140.413 en 2020, seguido de una recuperación parcial que alcanza los 278.953 arrestos en 2025.

Esta constatación reorienta el encargo. El objetivo del equipo consultor no consiste en revertir una crisis, sino en identificar dónde persiste la concentración del problema y cómo asignar recursos de manera más eficiente sobre un territorio desigual. La pregunta pertinente no es cuánto reducir, sino dónde y sobre quién intervenir.

1.4 Objetivo de negocio del equipo consultor

Objetivo general

Diseñar un plan de acción territorializado, sustentado en el procesamiento analítico de datos abiertos de la ciudad de Nueva York, que permita al equipo de gobierno priorizar la asignación de recursos en las zonas de mayor incidencia de arrestos y de siniestros viales, incorporando las condiciones socioeconómicas y educativas como factores de contexto del diagnóstico.

Objetivos específicos

1. Caracterizar la distribución territorial y temporal de los arrestos y de los siniestros viales, empleando indicadores normalizados por población que permitan comparar distritos de tamaños distintos.
2. Identificar las unidades geográficas de mayor incidencia con el mayor grado de desagregación que los datos permitan, a fin de orientar intervenciones focalizadas en lugar de políticas uniformes.
3. Describir la coincidencia territorial entre los indicadores de seguridad y los de pobreza y desempeño educativo, referidos todos a un mismo año.
4. Determinar si el ordenamiento territorial de los indicadores es estable en el tiempo, de lo cual depende la vigencia de cualquier priorización que se recomiende.
5. Establecer una línea base verificable y reproducible que haga posible evaluar el efecto de las intervenciones que se implementen.

2. Selección de los datos a utilizar

2.1 Conjuntos de datos seleccionados

Se emplean nueve conjuntos de datos. Cinco corresponden a los suministrados en el enunciado del caso y cuatro fueron incorporados por el equipo consultor, acogiéndose a la autorización expresa de investigar fuentes actualizadas.

Origen	Conjunto de datos	Registros	Atrib.	Periodo
Enunciado	NYPD Arrest Data (Year to Date)	141.870	19	Ene-Jun 2026
Enunciado	NYCgov Poverty Measure Data (2018)	68.273	61	2018
Enunciado	Motor Vehicle Collisions – Vehicles	4.551.002	25	2012–2026
Enunciado	2012 SAT Results	478	6	2012
Enunciado	NY SAT Suite of Assessments Report	20 págs.	—	2024
Equipo	Motor Vehicle Collisions – Crashes	2.269.187	29	2012–2026
Equipo	NYPD Arrests Data (Historic)	6.264.978	19	2006–2025
Equipo	ACS PUMS 2023, estado de Nueva York	206.408	287	2023
Equipo	Graduation results, cohortes 2012–2019	321.002	29	2016–2023
Equipo	NYC Regents Exam Results	82.964	18	2015–2019

Se añade además el cruce oficial tracto-PUMA del Censo, empleado para derivar el distrito en los microdatos de pobreza. El total asciende a 2,8 GB de datos en el clúster.

2.2 Justificación de la selección

La selección responde directamente al objetivo de negocio. Los conjuntos de arrestos y de siniestros constituyen la medición de los dos indicadores que motivan el encargo. Los de pobreza y educación aportan las variables de contexto que permiten pasar de una descripción del fenómeno a una hipótesis sobre sus condiciones asociadas, que es lo que distingue un plan de acción de un informe estadístico.

Los microdatos de pobreza cumplen además una función instrumental determinante: sus factores de expansión muestral permiten estimar la población de cada distrito y, con ella, normalizar los indicadores de seguridad. Sin esa normalización, cualquier priorización territorial quedaría sesgada hacia los distritos más poblados.

2.3 Conjuntos incorporados por el equipo consultor

La incorporación de los cuatro conjuntos complementarios obedece a dos limitaciones distintas de los datos originalmente suministrados: la ausencia de atributos indispensables y el desfase temporal entre fuentes.

Motor Vehicle Collisions – Crashes

El conjunto Vehicles registra un vehículo por fila y describe las circunstancias del hecho, pero carece por completo de atributos de localización y de gravedad: no contiene distrito, código postal, coordenadas ni número de heridos o fallecidos. Con ese conjunto de manera aislada resulta imposible responder dónde

se concentran los siniestros, que es el indicador territorial solicitado. El conjunto Crashes aporta esos atributos y se vincula con Vehicles mediante el identificador COLLISION_ID.

NYPD Arrests Data (Historic)

El conjunto del año en curso abarca únicamente el primer semestre de 2026, lo que impide analizar tendencias interanuales y estacionalidad. El conjunto histórico comparte la misma estructura y extiende la cobertura hasta 2006, permitiendo construir una serie de 6.406.848 arrestos.

ACS PUMS 2023 y resultados de graduación

Ambos responden al problema de alineación temporal que se expone en el apartado siguiente, y sustituyen en el corte transversal a las fuentes de 2018 y 2012.

2.4 Alineación temporal de los conjuntos

El conjunto de pobreza suministrado corresponde a 2018 y el de resultados SAT a 2012, mientras que los de arrestos y siniestros alcanzan junio de 2026. Cruzar indicadores referidos a años distintos dentro de una misma tabla no resulta admisible desde el punto de vista metodológico: cualquier coincidencia territorial que se observara podría atribuirse al desfase y no al fenómeno estudiado.

El equipo verificó que la vía de la actualización directa está agotada. El portal NYC Open Data publica catorce ediciones de la medida de pobreza, de 2005 a 2018, sin que exista ninguna posterior; de los resultados SAT solo se encuentran disponibles las ediciones de 2010 y 2012. Los conjuntos suministrados son, en ambos casos, los más recientes publicados.

Se recurrió en consecuencia a dos fuentes equivalentes que sí alcanzan 2023:

- ACS PUMS 2023. Son los microdatos de persona de la American Community Survey, sobre los cuales el propio NYCgov construye su medida de pobreza, de modo que se preserve la continuidad metodológica. El archivo no incluye el condado, pero sí el PUMA; dado que los cinco distritos de Nueva York son condados, el distrito se deriva del cruce oficial tracto-PUMA del Censo. Se verificó que cada uno de los 55 PUMAs de la ciudad pertenece a un único distrito.
- Resultados de graduación por cohorte. La cohorte 2019 corresponde a la clase de 2023, lo que proporciona un indicador educativo contemporáneo de la pobreza medida.

Se adopta por consiguiente 2023 como año de referencia del corte transversal. Los análisis de serie temporal conservan la cobertura completa, puesto que una variable observada a lo largo del tiempo no requiere alineación alguna.

Los conjuntos de 2018 y 2012 se conservan en el análisis con una función distinta: la de contraste histórico que permite evaluar la persistencia del ordenamiento territorial, según se desarrolla en los elementos 11, 12 y 14 de la exploración.

Validación de la sustitución. La tasa de pobreza obtenida para el conjunto de la ciudad a partir del ACS, 18,00%, coincide con la cifra de 18,2% publicada para 2023, lo que confirma tanto la identificación de los códigos geográficos como la correcta aplicación de los factores de expansión.

2.5 Limitaciones reconocidas de la selección

- Granularidad geográfica desigual. Los arrestos ofrecen precinto policial, los siniestros ofrecen código postal y coordenadas, mientras que la pobreza solo permite descender hasta el PUMA, agregable a distrito. El distrito es, en consecuencia, la única unidad común y constituye el límite de cualquier cruce entre las tres fuentes.
- Lugar de ocurrencia frente a lugar de residencia. Los arrestos y los siniestros se registran donde suceden, no donde residen las personas involucradas. En distritos con elevada población flotante, como Manhattan, la normalización por población residente sobreestima las tasas resultantes.
- Comparabilidad entre medidas de pobreza. La medida NYCgov de 2018 y la del ACS de 2023 no son directamente comparables: la primera ajusta por costo de vida, impuestos y transferencias, mientras que la segunda emplea el umbral federal, que subestima la pobreza en una ciudad de costos elevados. El contraste entre ambas se presenta para apreciar la persistencia del ordenamiento, no para medir su variación.
- Población de referencia. La estimación poblacional derivada del ACS, 8.257.860 habitantes, corresponde a la población en viviendas y resulta por ello inferior a la cifra oficial de 8.585.000, que incluye la población en alojamientos colectivos.

2.6 Enlaces de acceso a las fuentes

- NYPD Arrest Data (Year to Date): https://data.cityofnewyork.us/Public-Safety/NYPD-Arrest-Data-Year-to-Date-/uip8-fykc/about_data
- NYCgov Poverty Measure Data (2018): https://data.cityofnewyork.us/City-Government/NYCgov-Poverty-Measure-Data-2018-/cts7-vksw/about_data
- Motor Vehicle Collisions – Vehicles: https://data.cityofnewyork.us/Public-Safety/Motor-Vehicle-Collisions-Vehicles/bm4k-52h4/about_data
- 2012 SAT Results: https://data.cityofnewyork.us/Education/2012-SAT-Results/f9bf-2cp4/about_data
- New York SAT Suite of Assessments Annual Report 2024: <https://reports.collegeboard.org/media/pdf/2024-new-york-sat-suite-of-assessments-annual-report-ADA.pdf>
- Motor Vehicle Collisions – Crashes: https://data.cityofnewyork.us/Public-Safety/Motor-Vehicle-Collisions-Crashes/h9gi-nx95/about_data
- NYPD Arrests Data (Historic): https://data.cityofnewyork.us/Public-Safety/NYPD-Arrests-Data-Historic-/8h9b-rp9u/about_data
- ACS 2023 Public Use Microdata Sample, Nueva York: https://www2.census.gov/programs-surveys/acs/data/pums/2023/1-Year/csv_pny.zip
- | Cruce | 2020 | Census | Tract | to | 2020 | PUMA: |
|---|------|--------|-------|----|------|-------|
| https://www2.census.gov/geo/docs/reference/puma2020/2020_Census_Tract_to_2020_PUMA.txt | | | | | | |
- Graduation results for Cohorts 2012 to 2019: https://data.cityofnewyork.us/Education/Graduation-results-for-Cohorts-2012-to-2019-Classes/mjm3-8dw8/about_data
- NYC Regents Exam Results 2014-15 a 2018-19: https://data.cityofnewyork.us/Education/2014-15-2018-19-NYC-Regents-Exam-Public/2h3w-9uj9/about_data

3. Colección y descripción de los datos

3.1 Características del clúster de procesamiento

El procesamiento se ejecuta sobre un clúster Apache Spark de seis nodos desplegado sobre máquinas virtuales de la universidad, en modo standalone, con un nodo que desempeña simultáneamente los roles de maestro y trabajador.

Nodo	Dirección IP	Rol	Procesador	Núcleos	RAM	Disco
NBDG41	10.43.97.58	Maestro + Trabajador	Xeon Gold 5520+	4	15 GB	24 GB
NBDG42	10.43.97.59	Trabajador	Xeon Gold 5520+	4	15 GB	24 GB
NBDG44	10.43.97.61	Trabajador	Xeon Gold 6348	4	15 GB	24 GB
NBDG46	10.43.97.63	Trabajador	Xeon Gold 6240R	4	15 GB	24 GB
NBDG50	10.43.97.67	Trabajador	Xeon E5-2650 v4	4	15 GB	24 GB
NBDG54	10.43.97.71	Trabajador	Xeon Gold 6348	4	15 GB	24 GB

Capacidad agregada verificada mediante la interfaz de administración del maestro: 24 núcleos de procesamiento y 88.056 MB de memoria destinada a ejecutores, correspondientes a 14.676 MB por nodo trabajador. La ejecución completa del cuaderno de análisis requiere aproximadamente tres minutos.

Pila de software y configuración

Componente	Versión o valor
Sistema operativo	Rocky Linux 9.8 (Blue Onyx), kernel 5.14.0
Motor de procesamiento	Apache Spark 4.2.0, modo standalone
Bibliotecas Hadoop	Apache Hadoop 3.5.0
Máquina virtual Java	OpenJDK 17.0.20.1 LTS
Intérprete de Python	CPython 3.11.16
spark.executor.memory	12 GB, con 2 GB de sobrecarga
spark.executor.cores	4
spark.scheduler.mode	FAIR
spark.dynamicAllocation.enabled	true
Interfaz de administración	http://10.43.97.58:8081

Se deja constancia de dos particularidades del entorno que condicionaron la implementación. En primer lugar, Apache Spark 4.2.0 requiere Python 3.10 o superior, mientras que el intérprete instalado en el sistema operativo corresponde a la versión 3.9; fue necesario desplegar CPython 3.11.16 en el directorio compartido del clúster. En segundo lugar, Spark 4 aplica semántica ANSI en las conversiones de tipo, de modo que un valor no numérico interrumpe la ejecución en lugar de resolverse como nulo, lo que exigió emplear conversiones tolerantes en los conjuntos educativos.

Arquitectura de almacenamiento

El clúster no dispone de un sistema de archivos distribuido HDFS en operación. Si bien las bibliotecas de Hadoop se encuentran instaladas, no existen demonios NameNode ni DataNode activos, y el sistema de archivos por defecto corresponde al local de cada máquina. La compartición se resuelve mediante NFS versión 4.2: el nodo maestro exporta el directorio /opt/cluster y los cinco trabajadores lo montan en esa misma ruta, de manera que todos los ejecutores acceden a los datos con rutas idénticas.

Esta arquitectura tiene una consecuencia de diseño que conviene señalar: al centralizarse el almacenamiento en el nodo maestro, toda lectura de los ejecutores atraviesa la red hacia dicho nodo, que se constituye en el limitante de entrada y salida del sistema.

3.2 Procedimiento de colección y verificación

Los conjuntos se descargaron desde el portal NYC Open Data mediante su interfaz de exportación en formato CSV y desde el repositorio público del Censo de los Estados Unidos, totalizando 2,8 GB, y se transfirieron al directorio /opt/cluster/data del clúster. La integridad de la transferencia se verificó mediante la comparación de las sumas de control MD5 de origen y destino para la totalidad de los archivos, con coincidencia en todos los casos.

Como verificación adicional, los conteos de registros obtenidos en Spark se contrastaron con los metadatos publicados por el portal, con coincidencia exacta.

3.3 Descripción general del contenido

Conjunto	Registros	Atrib.	Cobertura temporal	Unidad de observación
Arrestos (histórico)	6.264.978	19	01/01/2006 – 31/12/2025	Un arresto
Arrestos (año en curso)	141.870	19	01/01/2026 – 30/06/2026	Un arresto
Siniestros – Crashes	2.269.187	29	01/07/2012 – 11/06/2026	Un siniestro
Siniestros – Vehículos	4.551.002	25	01/07/2012 – 11/06/2026	Un vehículo
ACS PUMS 2023	206.408	287	Año 2023	Una persona
Pobreza NYCgov 2018	68.273	61	Año 2018	Una persona
Graduación por cohorte	321.002	29	Cohortes 2012–2019	Un grupo-cohorte
Regents	82.964	18	2014-15 – 2018-19	Institución-examen
Resultados SAT	478	6	Año 2012	Una institución

De los 206.408 registros del ACS correspondientes al estado de Nueva York, 66.390 pertenecen a la ciudad una vez aplicado el cruce de PUMAs. La unión de las dos tablas de arrestos, previa normalización del nombre de su último atributo, produce una serie continua de 6.406.848 registros que abarca veinte años y medio.

3.4 Tipos de datos y significado de los atributos

3.4.1 Arrestos del NYPD

Atributo	Tipo	Significado
----------	------	-------------

ARREST_KEY	string	Identificador único del arresto
ARREST_DATE	date	Fecha del arresto (origen en formato MM/dd/yyyy)
PD_CD / KY_CD	integer	Códigos interno y general de clasificación del delito
PD_DESC / OFNS_DESC	string	Descripciones detallada y general del delito
LAW_CODE	string	Referencia al artículo de la ley infringida
LAW_CAT_CD	string	Gravedad: F felony, M misdemeanor, V violation, I infracción
ARREST_BORO	string	Distrito: B Bronx, K Brooklyn, M Manhattan, Q Queens, S Staten Island
ARREST_PRECINCT	integer	Precinto policial donde se produjo el arresto
JURISDICTION_CODE	integer	Jurisdicción responsable del procedimiento
AGE_GROUP	string	Grupo etario: <18, 18-24, 25-44, 45-64, 65+
PERP_SEX / PERP_RACE	string	Sexo y grupo racial de la persona arrestada
X_COORD_CD / Y_COORD_CD	double	Coordenadas planas del sistema estatal de Nueva York
Latitude / Longitude	double	Coordenadas geográficas
geo_punto	string	Geometría POINT; denominada Lon_Lat o Location según la fuente

3.4.2 Siniestros viales – Crashes

Atributo	Tipo	Significado
crash_date / crash_time	date / string	Fecha y hora del siniestro
borough / zip_code	string	Distrito y código postal
latitude / longitude	double	Coordenadas geográficas del punto
on_street_name	string	Vía principal donde ocurrió el siniestro
cross_street_name	string	Vía transversal de referencia
off_street_name	string	Dirección cuando no corresponde a una intersección
n_persons_injured / killed	integer	Total de personas heridas y fallecidas
n_pedestrians_injured / killed	integer	Peatones heridos y fallecidos
n_cyclist_injured / killed	integer	Ciclistas heridos y fallecidos
n_motorist_injured / killed	integer	Ocupantes de vehículo heridos y fallecidos
factor_1 ... factor_5	string	Factores contribuyentes atribuidos a cada vehículo
collision_id	integer	Identificador del siniestro; vincula con Vehicles
tipo_veh_1 ... tipo_veh_5	string	Tipo de cada vehículo involucrado

3.4.3 Siniestros viales – Vehicles

Atributo	Tipo	Significado
unique_id	integer	Identificador del vehículo dentro del registro
collision_id	integer	Identificador del siniestro; vincula con Crashes
state_registration	string	Estado de matriculación del vehículo
vehicle_type / make / model /	string	Características del vehículo

year		
travel_direction	string	Sentido de circulación
vehicle_occupants	integer	Número de ocupantes
driver_sex	string	Sexo del conductor
driver_license_status / jurisdiction	string	Situación y origen de la licencia
pre_crash	string	Maniobra previa al siniestro
point_of_impact	string	Punto de impacto sobre el vehículo
vehicle_damage / _1 / _2 / _3	string	Zonas del vehículo con daño
public_property_damage	string	Existencia de daño a bien público
contributing_factor_1 / _2	string	Factores contribuyentes del vehículo

3.4.4 Pobreza: ACS PUMS 2023 y NYCgov 2018

El archivo del ACS contiene 287 atributos. Se relacionan los empleados en el análisis, junto con los del conjunto NYCgov utilizado como contraste.

Atributo	Tipo	Significado
PUMA (ACS)	string	Área de microdatos de uso público; se cruza a distrito
PWGTP (ACS)	double	Factor de expansión de la persona
POVPI (ACS)	double	Razón ingreso-umbral de pobreza; menor que 100 indica pobreza
AGEP / SEX / SCHL (ACS)	integer	Edad, sexo y nivel educativo alcanzado
pwgtp / wgtp (NYCgov)	integer	Factores de expansión de persona y de hogar
boro (NYCgov)	integer	1 Bronx, 2 Brooklyn, 3 Manhattan, 4 Queens, 5 Staten Island
nycgov_pov_stat	integer	Situación de pobreza: 1 en pobreza, 2 fuera
nycgov_income / threshold	double	Ingreso y umbral según la metodología NYCgov
lanx / eng (NYCgov)	integer	Idioma distinto del inglés en el hogar y su dominio

3.4.5 Educación: graduación, Regents y SAT

Atributo	Tipo	Significado
Report Category	string	Nivel de agregación: School, District, Borough, Citywide
Geographic Subdivision	string	Distrito al que corresponde la fila
Cohort Year	integer	Año de ingreso de la cohorte; 2019 es la clase de 2023
Cohort	string	Horizonte de medición: 4 year June, 4 year August
# Total Cohort / # Grads	integer	Estudiantes de la cohorte y graduados
% Grads	double	Tasa de graduación
School DBN (Regents y SAT)	string	Código de institución; el tercer carácter da el distrito
Mean Score (Regents)	double	Puntaje medio del examen; admite el marcador «s»
Total Tested (Regents)	integer	Número de estudiantes evaluados

sat_lectura / matematicas / escritura	string	Puntaje promedio por área; admite «s»
---------------------------------------	--------	---------------------------------------

4. Exploración de los datos

Se presentan catorce elementos de análisis obtenidos mediante el procesamiento distribuido de los conjuntos seleccionados. Los elementos de serie temporal emplean la cobertura completa de los datos; los de corte transversal se refieren todos al año 2023, conforme a la decisión de alineación expuesta en el apartado 2.4. El código que los genera constituye el anexo del presente documento.

Elemento 1. Evolución anual de los arrestos




Figura 1. Arrestos registrados por el NYPD entre 2006 y 2026. El valor de 2026 corresponde únicamente al primer semestre.

La serie describe tres fases bien diferenciadas: un periodo alto entre 2006 y 2012 que alcanza su máximo en 2010 con 422.322 arrestos; un descenso sostenido que se acelera hasta el mínimo de 140.413 en 2020; y una recuperación parcial que alcanza 278.953 arrestos en 2025, equivalente al 66% del máximo histórico.

Elemento 2. Arrestos por distrito: volumen absoluto frente a tasa poblacional




Figura 2. Arrestos por distrito en 2023, en valores absolutos y normalizados por cada cien mil habitantes.

Distrito	Arrestos 2023	Población 2023	Arrestos por 100.000 hab.
Brooklyn	62.395	2.560.271	2.437
Bronx	53.258	1.356.908	3.925
Manhattan	52.891	1.597.842	3.310

Queens	48.310	2.252.037	2.145
Staten Island	10.018	490.802	2.041

Este elemento sustenta una de las conclusiones centrales del diagnóstico. Brooklyn encabeza el volumen absoluto de arrestos, pero desciende al tercer lugar al considerar el tamaño de su población. El Bronx, segundo en términos absolutos, presenta la mayor incidencia real de la ciudad con 3.925 arrestos por cada cien mil habitantes, un 61% por encima de Brooklyn. Una priorización basada en cifras absolutas conduciría, por tanto, a asignar recursos al territorio equivocado.

Elemento 3. Composición por gravedad y tipo de delito

Categoría	Arrestos	% del total
Delito menor (misdemeanor)	4.110.313	64,15%
Delito grave (felony)	1.934.904	30,20%
Contravención (violation)	303.682	4,74%
Sin clasificar	30.444	0,48%
Infracción	27.505	0,43%




Figura 3. Quince categorías delictivas más frecuentes en el periodo 2006–2026.

Casi dos tercios de los arrestos corresponden a delitos menores. La categoría más frecuente, con 1.177.541 arrestos, es la relacionada con estupefacientes, que por sí sola representa el 18,4% de la serie completa y casi duplica a la segunda. Se trata de un dato de alto valor para el diseño del plan de acción, por cuanto sugiere que una fracción sustancial del indicador responde a una tipología delictiva específica, susceptible de abordarse mediante políticas distintas de las policiales.

Elemento 4. Perfil demográfico de las personas arrestadas




Figura 4. Distribución de los arrestos por grupo etario y sexo.

Grupo etario	Masculino	Femenino	Total	% femenino
Menor de 18	367.438	90.515	457.953	19,77%
18 a 24	1.270.031	259.407	1.529.438	16,96%
25 a 44	2.516.916	514.080	3.030.996	16,96%
45 a 64	986.923	187.343	1.174.266	15,95%
65 o más	53.988	9.271	63.259	14,66%

El grupo de 25 a 44 años concentra el 48,45% de los arrestos con sexo declarado. La participación femenina desciende de forma monótona con la edad, desde el 19,77% entre los menores de edad hasta el 14,66% entre los mayores de 65 años.

Elemento 5. Concentración territorial por precinto policial



Figura 5. Diez precintos con mayor número de arrestos entre 2023 y 2026.

Los diez precintos señalados concentran el 27,21% de los arrestos del periodo, pese a que la ciudad cuenta con setenta y siete precintos. Cuatro de los diez pertenecen al Bronx, lo que refuerza el hallazgo del Elemento 2. El precinto 14, correspondiente a Midtown South en Manhattan, encabeza la lista con 32.424 arrestos.

Elemento 6. Evolución y estacionalidad de los siniestros viales




Figura 6. Siniestros por año y distribución mensual acumulada del periodo 2013–2025.

Los siniestros alcanzan su máximo en 2018 con 231.564 registros y descienden de manera sostenida hasta 85.546 en 2025, lo que representa una reducción del 63%. El comportamiento mensual resulta comparativamente estable, con una leve disminución en febrero atribuible a su menor número de días.

Elemento 7. Distribución horaria de los siniestros




Figura 7. Siniestros viales según la hora del día.

La franja de mayor incidencia se sitúa a las 16:00 horas, con 161.385 siniestros, dentro de una banda crítica que se extiende de las 14:00 a las 18:00. Se observa asimismo un valor anómalo en la hora 0:00, con 75.806 registros, muy superior a los de las horas contiguas. Dicho comportamiento sugiere que el valor 00:00 opera como valor por defecto cuando la hora no se conoce, circunstancia que se aborda en el reporte de calidad.

Elemento 8. Gravedad de los siniestros por distrito




Figura 8. Siniestralidad normalizada y letalidad por distrito en 2023.

Distrito	Siniestros	Heridos	Fallecidos	Siniestros/100k	Letalidad %
Brooklyn	22.890	12.376	49	894	2,14
Queens	17.786	9.518	46	790	2,59
Manhattan	11.823	5.613	28	740	2,37
Bronx	10.507	5.811	25	774	2,38
Staten Island	2.724	1.366	5	555	1,84

El ordenamiento de la siniestralidad difiere del de los arrestos: Brooklyn encabeza la incidencia por habitante, mientras que el Bronx ocupa la tercera posición. Queens presenta la mayor letalidad de la ciudad, con 2,59 fallecidos por cada mil siniestros, y Staten Island la menor incidencia junto con la menor letalidad. Los dos indicadores de seguridad no identifican, por tanto, el mismo territorio prioritario.

Elemento 9. Factores contribuyentes declarados




Figura 9. Quince factores contribuyentes más frecuentes, excluidos los registros sin especificar.

La distracción del conductor domina de manera inequívoca, con 462.105 siniestros, cifra que triplica con holgura la del segundo factor. Los cinco primeros factores remiten a conductas de conducción y no a condiciones de la infraestructura, lo que orienta las recomendaciones hacia medidas de fiscalización y de cambio de comportamiento.

Debe advertirse que 756.643 siniestros, equivalentes al 33,3% del conjunto, registran el factor como «Unspecified». La jerarquía anterior describe, por tanto, únicamente los dos tercios de los casos en que el factor fue efectivamente consignado.

Elemento 10. Los datos ausentes como fenómeno temporal




Figura 10. Porcentaje de valores ausentes en Vehículos según el año de ocurrencia del siniestro.

Año	Registros	% sin sexo	% sin licencia	% sin marca
2012	198.968	100,0	100,0	100,0
2014	409.087	100,0	100,0	100,0
2015	434.607	99,9	99,9	99,9
2016	457.944	34,8	39,1	25,6
2017	464.544	21,2	24,1	10,1
2025	170.015	35,1	40,0	20,4

Este elemento constituye, a juicio del equipo consultor, uno de los hallazgos metodológicamente más relevantes de la exploración. La ausencia de datos no se distribuye de manera aleatoria ni se degrada progresivamente: cae de forma abrupta del 99,9% al 34,8% entre 2015 y 2016. Los atributos correspondientes al conductor y al vehículo sencillamente no se capturaban antes de 2016.

La consecuencia práctica es directa. Imputar esos valores equivaldría a fabricar información para más de 1,4 millones de registros en los que nunca se recogió dato alguno. El tratamiento correcto consiste en restringir la ventana temporal de análisis a partir de 2016 para toda variable relativa al conductor.

Elemento 11. Pobreza por distrito




Figura 11. Tasa de pobreza por distrito: estimación del ACS para 2023 frente a la medida NYCgov de 2018.

Distrito	Universo 2023	En pobreza 2023	Tasa 2023	Tasa 2018 (NYCgov)
Bronx	1.322.073	365.818	27,67%	27,10%
Brooklyn	2.532.309	476.995	18,84%	20,31%
Manhattan	1.541.691	247.200	16,03%	15,06%
Queens	2.223.873	307.577	13,83%	17,02%
Staten Island	485.385	61.634	12,70%	16,00%

La tasa obtenida para el conjunto de la ciudad en 2023, 18,00%, coincide con la cifra de 18,2% publicada para ese año, lo que valida la identificación de los códigos geográficos y la aplicación de los factores de expansión. El Bronx mantiene la primera posición en ambas mediciones, con una diferencia de casi quince puntos porcentuales frente a Staten Island.

La comparación entre columnas debe interpretarse con cautela: la medida NYCgov ajusta por costo de vida, impuestos y transferencias, mientras que la del ACS emplea el umbral federal. Las diferencias observadas en Queens y Staten Island responden en parte a esa distinción metodológica y no necesariamente a una mejora real.

Elemento 12. Desempeño educativo por distrito




Figura 12. Tasa de graduación a cuatro años de la clase de 2023.

Distrito	Cohorte	Graduados	Tasa de graduación
Staten Island	4.583	3.900	85,1%
Queens	18.712	15.727	84,0%
Manhattan	14.660	11.888	81,1%
Brooklyn	19.682	15.698	79,8%
Bronx	12.256	9.455	77,1%

El indicador educativo alineado con el año de referencia es la tasa de graduación a cuatro años de la clase de 2023, correspondiente a la cohorte que ingresó en 2019. La diferencia entre el distrito de mejor y peor desempeño asciende a ocho puntos porcentuales.

Persistencia del ordenamiento educativo

Cabe preguntarse si recurrir a un único año introduce arbitrariedad. Se contrastan para ello tres mediciones distintas separadas por once años: el puntaje SAT de 2012 que figura en el enunciado, el puntaje medio de los exámenes Regents de 2019 y la tasa de graduación de la clase de 2023.

Distrito	SAT 2012	Regents 2019	Graduación 2023	Puesto SAT	Puesto Reg.	Puesto grad.
Bronx	1.144,6	66,8	77,1%	1	1	1
Brooklyn	1.167,4	70,3	79,8%	2	2	2
Manhattan	1.260,2	72,7	81,1%	3	5	3
Queens	1.275,4	72,1	84,0%	4	4	4
Staten Island	1.359,2	71,9	85,1%	5	3	5

El resultado es parcialmente concluyente. El puntaje SAT de 2012 y la tasa de graduación de 2023 producen un ordenamiento idéntico, pese a mediar once años y tratarse de mediciones de naturaleza distinta. El examen Regents discrepa en Manhattan y Staten Island, lo que resulta atribuible a que mide la aprobación de exámenes concretos y depende de qué alumnos se presentan a cuáles.

Las dos primeras posiciones desfavorables, Bronx y Brooklyn, son idénticas en las tres mediciones. Cabe concluir que la identificación del territorio educativamente más rezagado no depende del año ni del instrumento empleado, mientras que el ordenamiento entre los distritos de mejor desempeño sí es sensible a ambos factores.

Elemento 13. Convergencia territorial de los indicadores

Se consolidan en una sola tabla los indicadores construidos, todos correspondientes a 2023, lo que permite apreciar si los distritos con mayor incidencia de arrestos y siniestros coinciden con aquellos de mayor pobreza y menor desempeño educativo.

Distrito	Arrestos/100k	Siniestros/100k	Letalidad ‰	Pobreza	Graduación
Bronx	3.925	774	2,38	27,67%	77,1%
Manhattan	3.310	740	2,37	16,03%	81,1%
Brooklyn	2.437	894	2,14	18,84%	79,8%
Queens	2.145	790	2,59	13,83%	84,0%
Staten Island	2.041	555	1,84	12,70%	85,1%

Ordenamiento de los distritos según cada indicador, donde la posición 1 corresponde a la situación más desfavorable:

Distrito	Arrestos	Siniestros	Pobreza	Graduación (menor tasa)
Bronx	1	3	1	1
Manhattan	2	4	3	3
Brooklyn	3	1	2	2
Queens	4	2	4	4

Staten Island	5	5	5	5
---------------	---	---	---	---

El Bronx ocupa la primera posición desfavorable en arrestos, pobreza y rezago educativo, y la tercera en siniestralidad. Staten Island ocupa la quinta posición en los cuatro indicadores. La coincidencia entre seguridad ciudadana, pobreza y educación es, por tanto, notable; la siniestralidad vial sigue en cambio un patrón propio, encabezado por Brooklyn.

Manhattan merece una advertencia específica: ocupa la segunda posición en arrestos por habitante pese a registrar una tasa de pobreza inferior a la media de la ciudad. La explicación más plausible es metodológica. Los arrestos se contabilizan en el lugar de ocurrencia y no en el de residencia, y Manhattan recibe a diario una población flotante de trabajadores y visitantes que supera ampliamente a sus 1,60 millones de residentes. El denominador empleado subestima, por consiguiente, la población realmente expuesta.

Se advierte expresamente que lo anterior constituye una descripción de coincidencia territorial y en ningún caso una relación de causalidad. Su contrastación formal corresponde a la entrega final del proyecto.

Elemento 14. Estabilidad del ordenamiento territorial

El corte transversal se construyó sobre 2023, pero las recomendaciones del plan de acción se aplicarán en el presente. Procede entonces verificar si el ordenamiento de los distritos se mantiene a lo largo del tiempo. Se emplea la población de 2023 como denominador en todos los años, de modo que la comparación aísle la variación del numerador.




Figura 13. Evolución de las tasas por cien mil habitantes de arrestos y siniestros, por distrito.

Arrestos: ordenamiento estable

Distrito	2015	2018	2021	2023	2025
Bronx	2	1	1	1	1
Manhattan	1	2	2	2	2
Brooklyn	3	3	3	3	3
Queens	4	4	5	4	4
Staten Island	5	5	4	5	5

El Bronx ocupa la primera posición en 2018, 2021, 2023 y 2025, y cada distrito ocupa como máximo dos posiciones distintas en diez años. Un diagnóstico de arrestos construido sobre cualquier año reciente resulta por tanto válido para orientar la priorización actual.

Siniestros: ordenamiento inestable

Distrito	2015	2018	2021	2023	2025
Manhattan	1	1	4	4	2
Brooklyn	2	2	2	1	1
Queens	3	3	3	2	3
Bronx	4	4	1	3	4
Staten Island	5	5	5	5	5

El comportamiento es radicalmente distinto. Manhattan desciende de la primera a la cuarta posición, con una caída de 2.662 a 740 siniestros por cien mil habitantes entre 2015 y 2023, y el Bronx oscila entre la primera y la cuarta. Únicamente Staten Island mantiene una posición invariable.

De ello se desprende una conclusión operativa de interés para el equipo de gobierno: la priorización territorial en materia de seguridad ciudadana puede apoyarse en un diagnóstico estable, mientras que la priorización en materia de seguridad vial debe recalcularse de manera periódica. El caso de Manhattan constituye además la mejora más pronunciada de la ciudad y merece estudio específico como posible referencia de política pública.

5. Reporte de calidad de datos

5.1 Conteo de valores faltantes

El conteo considera de manera conjunta los valores nulos y las cadenas vacías, dado que la exportación en formato CSV representa la ausencia de dato de ambas maneras de forma indistinta. Los conjuntos exhiben comportamientos marcadamente distintos.

Arrestos: calidad elevada

Atributo	Faltantes	% del total
LAW_CAT_CD	26.464	0,42%
KY_CD	9.811	0,16%
OFNS_DESC / PD_DESC	9.169	0,15%
PD_CD	884	0,01%
ARREST_BORO	8	0,00%
ARREST_DATE, ARREST_PRECINCT, PERP_SEX, PERP_RACE	0	0,00%

Sobre 6.264.978 registros, el atributo más afectado no alcanza el medio punto porcentual. Los atributos requeridos para el análisis territorial se encuentran íntegros.

Siniestros – Crashes: deficiencia geográfica

Atributo	Faltantes	% del total
tipo_veh_5	2.259.199	99,56%
factor_5	2.258.873	99,55%
off_street_name	1.862.411	82,07%
cross_street_name	870.164	38,35%
zip_code	691.703	30,48%
borough	691.375	30,47%
latitude / longitude	240.806	10,61%
n_persons_killed	8.913	0,39%

La ausencia de distrito en casi un tercio de los registros constituye la principal limitación del conjunto. Los atributos relativos al cuarto y quinto vehículo presentan ausencias superiores al 98%, si bien ello no constituye un defecto: la inmensa mayoría de los siniestros involucra uno o dos vehículos.

Siniestros – Vehicles: degradación estructural

Atributo	Faltantes	% del total
public_property_damage_type	4.519.917	99,32%
vehicle_model	4.490.072	98,66%
driver_license_status	2.456.358	53,97%
driver_sex	2.349.139	51,62%
vehicle_year	1.981.905	43,55%
contributing_factor_1	170.464	3,75%

Conforme se demostró en el Elemento 10, esta degradación obedece a una modificación del formulario de captura y no a un deterioro aleatorio de la calidad.

5.2 Valores faltantes encubiertos bajo un marcador

El equipo consultor identificó que el conteo de nulos resulta insuficiente en los conjuntos educativos, por cuanto la ausencia de dato se representa mediante un valor válido. El Departamento de Educación sustituye el valor por el literal «s» en las instituciones con menos de cinco estudiantes, por razones de confidencialidad.

Se trata de una convención aplicada de manera sistemática y no de una peculiaridad de un único conjunto. El efecto cuantificado es el siguiente:

Conjunto	Filas afectadas	Total	% del conjunto
Regents (puntaje medio)	33.112	82.964	39,91%
Graduación (tasa)	81.688	321.002	25,45%
SAT 2012 (cuatro columnas)	57	478	11,92%

El conteo de nulos sobre el conjunto SAT arrojaba cero ausencias en los seis atributos, lo que sugería una calidad perfecta. Un reporte de calidad que solo busque nulos pasaría por alto casi el 40% del conjunto de Regents.

Esta circunstancia tuvo además una consecuencia técnica. Apache Spark 4 aplica semántica ANSI en las conversiones de tipo: al encontrar el literal «s» en una columna que se convierte a número, interrumpe la ejecución del trabajo con el error CAST_INVALID_INPUT en lugar de resolver el valor como nulo. Fue necesario emplear la función try_cast, que tolera la entrada malformada.

Se identificó asimismo un segundo marcador encubierto en los siniestros. La hora 0:00 registra 75.806 eventos, frente a 40.498 de la hora siguiente y 63.665 de la anterior. El exceso resulta incompatible con un patrón de movilidad real y sugiere el empleo de 00:00 como valor por defecto ante el desconocimiento de la hora.

5.3 Valores ausentes frente a valores no aplicables

No todo valor vacío constituye un dato faltante. En el conjunto de pobreza de 2018, la variable eng, que mide el dominio del idioma inglés, solo se diligencia para las personas que declaran hablar otro idioma en el hogar. El contraste con su condición de aplicabilidad arroja el siguiente resultado:

Condición (lanx)	Personas	Registros sin eng	Interpretación
1 — Habla otro idioma	30.716	0	Diligenciado en su totalidad
2 — Solo inglés	34.024	34.024	No aplica por definición
Nulo — menores de 5 años	3.533	3.533	Fuera del universo de la pregunta

En consecuencia, el conjunto no presenta valor faltante alguno en dicha variable: los 37.557 registros vacíos responden a la estructura del cuestionario. El mismo criterio se aplica a la variable POVPI del ACS, cuya ausencia identifica a la población situada fuera del universo de pobreza, esto es, la institucionalizada y los menores de quince años no emparentados. Dicha población, 152.529 personas ponderadas, se excluye del denominador conforme al criterio del propio Censo.

5.4 Técnicas propuestas para el tratamiento

Situación	Alcance	Técnica propuesta	Justificación
borough ausente en Crashes	30,47%	Imputación geoespacial a partir de las coordenadas	Solo el 10,61% carece de coordenadas, de modo que unos 450.000 registros admiten recuperación mediante contraste con los polígonos distritales
Coordenadas ausentes	10,61%	Exclusión del análisis territorial	No existe información alternativa que permita su recuperación
Atributos del conductor en Vehicles	51,62%	Restricción de la ventana temporal a 2016 en adelante	La ausencia es estructural y anterior a la captura del dato; imputarla equivaldría a fabricar información
Marcador «s» en Regents, graduación y SAT	hasta 39,91%	Conversión tolerante a nulo mediante try_cast y exclusión de los promedios	El valor suprimido no admite estimación; además su conversión estricta interrumpe la ejecución en Spark 4
Hora 0:00 en Crashes	3,34%	Marcado como hora desconocida	Su conservación distorsionaría el análisis de franjas horarias
LAW_CAT_CD ausente	0,42%	Imputación por moda	La gravedad se encuentra determinada por la

		condicionada a KY_CD	categoría delictiva
factor_1 sin especificar	33,3%	Conservación como categoría propia	«Unspecified» es una respuesta válida del formulario y no una ausencia
Variables eng y POVPI	55,0% / 1,8%	Ningún tratamiento	Corresponden a valores no aplicables y no a datos faltantes

6. Planteamiento de preguntas sobre los datos

Se formulan a continuación diez preguntas de negocio derivadas del objetivo de consultoría, a las cuales se dará respuesta en la entrega final del proyecto. Todas ellas resultan abordables con los conjuntos seleccionados y con la infraestructura descrita.

Pregunta 1. ¿Cuáles son los diez precintos policiales con mayor tasa de arrestos por cada cien mil habitantes y qué composición delictiva presentan?

Pertinencia: Permite pasar de la priorización por distrito a la priorización por precinto, que es la unidad sobre la que efectivamente se asignan recursos policiales.

Pregunta 2. ¿En qué medida la tasa de pobreza de un distrito se asocia con su tasa de arrestos, una vez controlado el tamaño de la población, empleando datos del mismo año?

Pertinencia: Contrasta formalmente la coincidencia territorial descrita en el Elemento 13, sobre una base temporalmente homogénea.

Pregunta 3. ¿Por qué la siniestralidad vial no sigue el mismo patrón territorial que los arrestos, y qué distingue a Brooklyn del Bronx en este aspecto?

Pertinencia: Los dos indicadores del encargo identifican territorios prioritarios distintos, lo que obliga a explicar la divergencia antes de recomendar una asignación de recursos.

Pregunta 4. ¿Qué explica la caída de Manhattan desde la primera hasta la cuarta posición en siniestralidad, y qué elementos de esa experiencia resultan transferibles?

Pertinencia: Es la mejora más pronunciada que registran los datos; identificar su causa tiene un valor directo para el diseño de la intervención.

Pregunta 5. ¿Qué corredores viales concentran el mayor número de siniestros con víctimas, y cuántos de ellos se ubican en los distritos de mayor pobreza?

Pertinencia: El atributo `on_street_name` permite descender de la escala distrital a la de vía, que es la escala de la intervención en infraestructura.

Pregunta 6. ¿Qué factores contribuyentes se asocian con mayor letalidad y no únicamente con mayor frecuencia?

Pertinencia: La distracción domina en frecuencia, pero no necesariamente en gravedad. La distinción resulta determinante para priorizar medidas.

Pregunta 7. ¿Cómo ha variado la composición por gravedad de los arrestos entre 2006 y 2026, y qué revela esa variación sobre el cambio en las prácticas de aplicación de la ley?

Pertinencia: Un descenso de arrestos con recomposición hacia delitos graves admite una lectura distinta de un descenso uniforme.

Pregunta 8. ¿Existe asociación entre la tasa de graduación de un distrito y su tasa de arrestos de personas menores de 18 años?

Pertinencia: Vincula el conjunto educativo con el indicador de seguridad en el grupo etario sobre el cual la intervención preventiva resulta más eficaz.

Pregunta 9. ¿Qué combinación de tipo de vehículo, maniobra previa y punto de impacto concentra los siniestros con fallecidos a partir de 2016?

Pertinencia: Explora el conjunto Vehicles dentro de la ventana temporal en que sus atributos resultan fiables.

Pregunta 10. ¿Qué porcentaje de los arrestos y de los siniestros se concentraría en el diez por ciento de las zonas más críticas, y qué cobertura alcanzaría una intervención focalizada en ellas?

Pertinencia: Cuantifica el retorno esperado de la focalización frente a una política uniforme, que es el argumento central ante los tomadores de decisiones.

7. Filtros, limpieza y transformación inicial

Se relacionan las operaciones ya aplicadas sobre los datos, así como aquellas previstas para la entrega final.

7.1 Transformaciones aplicadas

Transformación	Conjunto	Descripción
Conversión de fechas	Arrestos, Crashes, Vehicles	Los campos de fecha se reciben como texto en formato MM/dd/yyyy y se convierten a tipo date; sin esta conversión permanecerían como cadenas y no admitirían operaciones temporales
Normalización de nombres	Arrestos	El conjunto histórico denomina Lon_Lat al último atributo y el del año en curso lo denomina Location. Se unifican como geo_punto antes de la unión, pues de lo contrario se produciría un desplazamiento silencioso de columnas
Conversión a snake_case	Crashes, Vehicles, pobreza	Los nombres con espacios y mayúsculas se normalizan para admitir su uso directo en expresiones SQL sin necesidad de entrecomillado
Unión de series	Arrestos	Unión por nombre de las tablas histórica y del año en curso, generando una serie continua de 6.406.848 registros
Derivación del distrito desde el PUMA	ACS PUMS 2023	Cruce con el archivo oficial tracto-PUMA del Censo, que aporta el código de condado. Se verificó que cada uno de los 55 PUMAs de la ciudad corresponde a un único distrito
Estandarización poblacional	Arrestos, Crashes, ACS	Cálculo de indicadores por cada cien mil habitantes empleando como denominador la población estimada con los factores de expansión del mismo año de referencia
Alineación al año de referencia	Arrestos, Crashes	Filtrado al año 2023 para todo análisis de corte transversal, conservando la serie completa en los análisis de tendencia
Conversión tolerante de tipos	Regents, graduación	Empleo de try_cast en lugar de cast, dado que la semántica ANSI de Spark 4 interrumpe la ejecución al encontrar el marcador de supresión «S»
Derivación del distrito desde el DBN	SAT, Regents	Extracción del distrito a partir del tercer carácter del código de institución, lo que habilita el cruce territorial
Extracción de la hora	Crashes	Obtención de la hora a partir del texto de crash_time para el análisis de franjas

7.2 Filtros aplicados

- Lectura de Crashes con la opción multiLine activada. El conjunto contiene un registro con un salto de línea embebido en un nombre de vía; sin dicha opción, Spark divide ese registro en dos filas defectuosas y altera el conteo total. La opción se aplica únicamente a este conjunto, ya que impide la división del archivo y reduce el paralelismo disponible.
- Restricción del conjunto ACS a los PUMAs de la ciudad, que reduce los 206.408 registros del estado a los 66.390 correspondientes a Nueva York.
- Selección de la cohorte 2019 con horizonte de cuatro años y categoría de todos los estudiantes en el conjunto de graduación, que es la combinación correspondiente a la clase de 2023 a nivel de distrito.
- Exclusión de registros sin distrito informado en los análisis territoriales de siniestros, con declaración expresa del alcance afectado.
- Exclusión del valor «Unspecified» en el análisis de factores contribuyentes, conservándolo no obstante en los conteos generales por tratarse de una respuesta válida del formulario.
- Exclusión de las instituciones con puntaje suprimido en el cálculo de promedios educativos, y de aquellas sin estudiantes evaluados en el promedio ponderado de Regents.

7.3 Procesos de limpieza previstos

Las técnicas enunciadas en el apartado 5.4 se implementarán en su totalidad durante la entrega final. Se priorizarán, por su impacto sobre la calidad del diagnóstico:

6. Imputación geoespacial del distrito para los siniestros que disponen de coordenadas pero carecen de distrito, con evaluación previa de su exactitud sobre los registros que cuentan con ambos datos.
7. Marcado de la hora 0:00 como desconocida en los siniestros.
8. Restricción de la ventana temporal a partir de 2016 para todo análisis que emplee atributos del conductor.
9. Construcción de un indicador educativo a nivel de institución, y no solo de distrito, que permita el cruce con el precinto policial.

7.4 Declaración sobre el estado de avance

De conformidad con lo previsto en el enunciado, el presente apartado recoge el avance alcanzado. La totalidad de las transformaciones relacionadas en 7.1 y de los filtros relacionados en 7.2 se encuentran implementados y ejecutados sobre el clúster; los procesos de limpieza descritos en 7.3 se hallan especificados y serán implementados en la entrega final.

Referencias

City of New York. NYPD Arrests Data (Historic). NYC Open Data. [Disponible en línea](#)

City of New York. NYPD Arrest Data (Year to Date). NYC Open Data. [Disponible en línea](#)

City of New York. Motor Vehicle Collisions – Crashes. NYC Open Data. [Disponible en línea](#)

City of New York. Motor Vehicle Collisions – Vehicles. NYC Open Data. [Disponible en línea](#)

City of New York. NYCgov Poverty Measure Data (2018). NYC Open Data. [Disponible en línea](#)

New York City Department of Education. 2012 SAT Results. NYC Open Data. [Disponible en línea](#)

New York City Department of Education. Graduation results for Cohorts 2012 to 2019. NYC Open Data. [Disponible en línea](#)

New York City Department of Education. NYC Regents Exam Results 2014-15 a 2018-19. NYC Open Data. [Disponible en línea](#)

U.S. Census Bureau. American Community Survey 2023, Public Use Microdata Sample, New York. [Disponible en línea](#)

U.S. Census Bureau. 2020 Census Tract to 2020 PUMA Relationship File. [Disponible en línea](#)

College Board. New York SAT Suite of Assessments Annual Report 2024. [Disponible en línea](#)

New York City Department of Transportation. Traffic Deaths Reach All-time Low, 2026. [Disponible en línea](#)

New York City Department of Transportation. Vision Zero Reimagined: A New Action Plan for Road Safety, 2026. [Disponible en línea](#)

New York City Department of City Planning. New York City's Population Estimates and Trends, julio de 2026. [Disponible en línea](#)

Office of the New York City Comptroller. Annual State of the City's Economy and Finances 2025. [Disponible en línea](#)

New York City Economic Development Corporation. State of the New York City Economy 2025. [Disponible en línea](#)

Anexo. El cuaderno de código que sustenta la totalidad de las cifras presentadas se adjunta como entrega1.ipynb, ejecutado sobre el clúster descrito en el apartado 3.1.